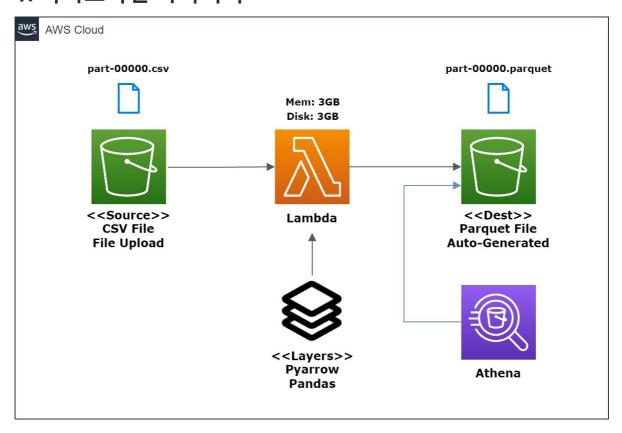
# [IGAWorks] 과제 전형 (제출용)

# 0. 제출 (ZIP) 파일 구조

```
assignment_knk/
pipeline_architecture.jpg
--- README.md
--- README.pdf
L— src
   --- etl
    L— lambda_handler.py
       —— 00.\ 00. create_part_00000.sql
       —— 00.\ 00. create_part_00001.sql
       — 01.\ active_user_by_date.sql
       - 02.\ total_price_active_user_by_date.sql
       — 03.\ active_user_by_event.sql
       — 04.\ active_user_by_campaign.sql
       — 05.\ total_price_active_user_by_campaign.sql
       — 06.\ active_user_total_price_by_country_campaign.sql
       — 07.\ hard_funnel(oracle).sql
       — 07.\ hard_funnel.sql
       — 08.\ hard_new_install_funnel_by_partner.sql
       — 09.\ hard_retention_by_dates(oracle).sql
         — query_result
           — 01.\ active_user_by_date.csv
           — 01.\ active_user_by_date.PNG
           — 02.\ total_price_active_user_by_date.csv
           — 02.\ total_price_active_user_by_date.PNG
           ____03.\ active_user_by_event.csv
           — 03.\ active_user_by_event.PNG
             — 04.∖ active_user_by_campaign.csv
           — 04.\ active_user_by_campaign.PNG
           — 05.\ total_price_active_user_by_campaign.csv
           — 05.\ total_price_active_user_by_campaign.PNG
           - 06.\ active_user_total_price_by_country_campaign.csv
           — 06.\ active_user_total_price_by_country_campaign.PNG
           — 07.\ hard_funnel.csv
           — 07.\ hard_funnel.PNG
           - 08.\ hard_new_install_funnel_by_partner.csv
           └─ 08.\ hard_new_install_funnel_by_partner.PNG
```

# 1. 파이프라인 아키텍처

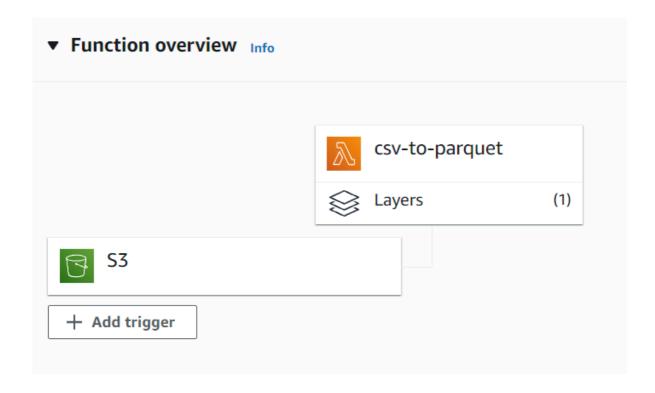


# 해당 아키텍처로 선택한 이유

- 과제 시작 직전에는 Ubuntu ECS 인스턴스 (컨테이너)에서 변환 작업을 하는줄 알았지만, 과제 목표중 하나인 ETL에 드는 노력을 0에 가깝게 합니다. 를 충족하지 못할거같아 과제 2일째 Pyspark 로 방향을 바꾸었습니다.
- S3에 파일이 업로드 될때마다 Spark Job을 Container로 기동시켜 변환을 하는 방법밖에 떠오르지 않아 시도해보았지만, SQS, ECS, EMR, Athena를 한번에 습득하기엔 Learning Curve가 너무 길고, Lambda, Athena로 파이프라인을 구현할 수 있을것 같아 해당 아키텍처를 선택했습니다.

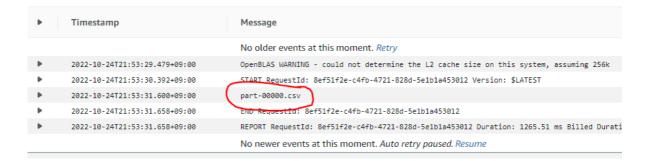
### **Data Flow**

**Trigger** 



source-part 라는 Bucket에 데이터가 들어오면 Lambda Function이 Trigger 되는 형식입니다.

### **CloudWatch Logs on lambda function**



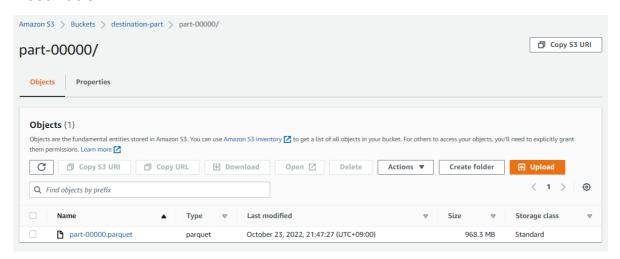
### Layers

- CSV to Parquet을 달성하기 위해 Lambda function에서 Pandas, Pyarrow Library를 Import 했습니다.
- 해당 library를 Import 하려면 제가 사용하고자 하는 library를 ZIP 형태로 묶어 layers 에 업로드합니다.



```
[root@networkserver PyVenv]# ls
lambda-pyarrow-3.8
[root@networkserver PyVenv]# ls -al lambda-pyarrow-3.8/
total 73972
                             4096 Oct 20 08:06 .
drwxr-xr-x.
            5 root root
drwxr-xr-x. 3 root root
                             4096 Oct 20 08:03 ...
                             4096 Oct 20 07:50 bin
drwxr-xr-x. 2 root root
                               40 Oct 20 07:50 gitignore
 rw-r--r--. 1 root root
             1 root root 75715591 Oct 20 08:06 layer.zip
drwxr-xr-x. 3 root root
                            4096 Oct 20 07:50 Lib
drwxr-xr-x. 16 root root
                             4096 Oct 20 08:03 python
                              228 Oct 20 07:50 pyvenv.cfg
-rw-r--r--. 1 root root
[root@networkserver PyVenv]# ls -al lambda-pyarrow-3.8/python/
total 100
                          4096 Oct 20 08:03 .
drwxr-xr-x. 16 root root
                          4096 Oct 20 08:06 ...
drwxr-xr-x. 5 root root
             2 root root
                         4096 Oct 20 08:03 bin
drwxr-xr-x.
drwxr-xr-x. 6 root root 4096 Oct 20 08:03 dateutil
drwxr-xr-x. 21 root root 4096 Oct 20 08:03 numpy
                        4096 Oct 20 08:03 numpy-1.23.4.dist-info
drwxr-xr-x. 2 root root
                         4096 Oct 20 08:03 numpy.libs
            2 root root
drwxr-xr-x.
drwxr-xr-x. 16 root root 4096 Oct 20 08:03 pandas
drwxr-xr-x. 2 root root 4096 Oct 20 08:03 pandas-1.5.1.dist-info
drwxr-xr-x. 9 root root 4096 Oct 20 08:03 pyarrow
drwxr-xr-x. 2 root root
                        4096 Oct 20 08:03 pyarrow-9.0.0.dist-info
drwxr-xr-x. 2 root root 4096 Oct 20 08:03 __pycache_
drwxr-xr-x. 2 root root 4096 Oct 20 08:03 python dateutil-2.8.2.dist-info
drwxr-xr-x. 4 root root
                         4096 Oct 20 08:03 pytz
                         4096 Oct 20 08:03 pytz-2022.5.dist-info
drwxr-xr-x. 2 root root
drwxr-xr-x. 2 root root
                          4096 Oct 20 08:03 six-1.16.0.dist-info
 rw-r--r--. 1 root root 34549 Oct 20 08:03 six.py
```

### **Destination**



• Lambda Function을 통해 변환 된 후, destination-part라는 Bucket으로 key가 생성 됩니다.

### **Lambda Function Source Code**

src/etl/lambda\_handler.py 에서 확인 하실 수 있습니다.

```
from io import StringIO
from io import BytesIO
from pyarrow import csv,parquet
import json
import boto3
import urllib.parse
import pandas as pd
import pyarrow as pa
endpoint_url = '*'
access_key = '*'
secret_key = '*'
s3_client = boto3.client('s3', region_name='ap-northeast2',
endpoint_url=endpoint_url, aws_access_key_id=access_key,
aws_secret_access_key=secret_key)
s3_resource = boto3.resource('s3', region_name='ap-northeast2',
endpoint_url=endpoint_url, aws_access_key_id=access_key,
aws_secret_access_key=secret_key)
def lambda_handler(event, context):
   csv_buffer = StringIO()
    par_buffer = BytesIO()
    bucket = event['Records'][0]['s3']['bucket']['name']
    csv = urllib.parse.unquote_plus(event['Records'][0]['s3']['object']['key'],
encoding='utf-8')
    dest = csv.replace(".csv", "")
   name = csv.replace('csv', 'parquet')
    if name == 'part-00000':
        col = ['identity_adid', 'os', 'model', 'country', 'event_name', 'log_id',
        resp = s3_client.get_object(Bucket=bucket, Key=csv)
        data = pd.read_csv(resp['Body'], sep=',')
        data.columns = col
        data = data.fillna(0)
        data =
data.astype({'identity_adid':'str','os':'str','model':'str','quantity':'int',
    elif name == 'part-00001':
```

```
data = pd.read_csv(resp['Body'], sep=',')
    data.columns = col
    data = data.astype({'identity_adid':'str', 'server_datetime':'str'})
    else:
        print("Not a valid input.")

try:
        data.to_parquet(par_buffer, engine='pyarrow', index=False)
        s3_resource.Object(f'destination-part/{dest}',

f'{name}').put(Body=par_buffer.getvalue())
    except Exception as e:
        print("Data Invalid.", e)
```

## 2. Athena

### **Event**

```
CREATE EXTERNAL TABLE event (

IDENTITY_ADID STRING,

OS STRING,

MODEL STRING,

COUNTRY STRING,

EVENT_NAME STRING,

LOG_ID STRING,

SERVER_DATETIME STRING,

QUANTITY INT,

PRICE FLOAT

) STORED AS PARQUET

LOCATION 's3://destination-part/part-00000/'

TBLPROPERTIES ('classification' = 'parquet')
```

### **Attribution**

```
CREATE EXTERNAL TABLE ATTRIBUTION (

PARTNER STRING,

CAMPAIGN STRING,

SERVER_DATETIME STRING,

TRACKER_ID STRING,

LOG_ID STRING,

ATTRIBUTION_TYPE INT,

IDENTITY_ADID STRING
) STORED AS PARQUET

LOCATION 's3://destination-part/part-00001/'

TBLPROPERTIES ('classification' = 'parquet')
```

# server\_datetime을 String으로 선언한 이유

- CSV에서 Parquet으로 변환시 datetime으로 선언했을 때는 문제가 되지 않았지만, Athena에서 Data를 조회할때마다 빈 화면이 보여 Parquet의 컬럼 타입이 안맞는다고 생각했습니다.
- 정확히 어떤 컬럼에서 에러가 발생하는지 찾기위해, 제 Hive Server에 직접 Parquet을 Load해보니 다음 과 같은 에러가 발생했습니다.
- org.apache.hadoop.io.LongWritable cannot be cast to org.apache.hadoop.hive.serde.io.TimestampWritable
- 어떤 이유인지 모르겠지만, Hive에서 server\_datetime을 지속적으로 LongWritable로 인식하여 timestamp로 load하지 못했던것입니다.

```
o # 초기에 'server_datetime'을 datetime 형식으로 변환 시도 했지만, LongWritable로
인식합니다
data['server_datetime'] = pd.to_datetime(data['server_datetime'])
```

• 해당 이유로인해, partition by server\_datetime 은 테이블 create시 선언하지 않고, query로 조 회할때 cast하여 사용했습니다.

# 3. Query Results

- sql 파일명 뒤에 (oracle)이 있는 파일은 athena query 결과가 확실하지 않아 oracle로 짜본 쿼리입니다.
- 9번 hard\_retention\_by\_dates(oracle).sql 은 athena로 해결하지 못해 oracle 쿼리로 짜보았습니다.

# query\_result 00. create\_part\_00000 00. create\_part\_00001 01. active\_user\_by\_date 02. total\_price\_active\_user\_by\_date 03. active\_user\_by\_event 04. active\_user\_by\_campaign 05. total\_price\_active\_user\_by\_campaign 06. active\_user\_total\_price\_by\_country\_ca... 07. hard\_funnel(oracle) 08. hard\_new\_install\_funnel\_by\_partner

09. hard\_retention\_by\_dates(oracle)